

Data Warehouse

Brazilian E-Commerce Olist

Relatorio Tecnico - Projeto de Banco de Dados / BI
FATEC Jundiai | 2026

Dataset	Brazilian E-Commerce Public Dataset by Olist
Fonte	Kaggle (CC BY-NC-SA 4.0)
Volume	99.441 pedidos 112.650 itens 9 arquivos CSV
Banco	DuckDB 1.5.3 (principal) + PostgreSQL 18 (bonus)
Periodo	Setembro/2016 – Outubro/2018
Receita	R\$ 13.494.401
Dashboard	https://projeto-dw-olist.streamlit.app

1. Introducao

Este projeto implementa um Data Warehouse (DW) completo sobre o dataset publico Brazilian E-Commerce by Olist, disponivel no Kaggle. O Olist e uma plataforma de e-commerce brasileira que conecta pequenos vendedores a grandes marketplaces. O dataset contem cerca de 100 mil pedidos realizados entre 2016 e 2018, com informacoes de clientes, produtos, vendedores, pagamentos, avaliacoes e logistica.

O objetivo e transformar esses dados brutos em informacao estruturada para apoiar decisoes de negocio, respondendo a cinco perguntas analiticas principais, alem de implementar todos os bonus previstos: dashboard interativo publicado, testes automatizados, comparacao DuckDB vs PostgreSQL.

1.1 Perguntas de Negocio

#	Pergunta	Tipo
1	Como evoluiram as vendas mes a mes ao longo de 2016–2018?	Temporal
2	Quais sao as 10 categorias de produto mais lucrativas?	Ranking
3	Qual categoria vende mais em cada estado brasileiro?	Multidimensional
4	Como cresce e como e a retencao da base de clientes?	Cohort
5	Quais estados tem maior ticket medio e melhor logistica?	KPI

2. Modelagem Dimensional

O modelo adotado e o Esquema Estrela com uma tabela fato central (fact_sales) e quatro dimensoes. O grain e 1 linha por item de pedido — cada linha representa um produto especifico dentro de um pedido.

2.1 Dimensoes

Dimensao	Grain	SCD	Linhas	Descricao
dim_date	1 por dia	N/A	1.461	Calendario Jan/2016 a Dez/2019
dim_customer	1 por versao	Type 2	96.096	Clientes com historico de localizacao
dim_product	1 por produto	Type 1	32.951	Produtos com categoria em ingles
dim_seller	1 por vend.	Type 1	3.095	Vendedores com dados geograficos

2.2 SCD Type 2 — dim_customer

Quando um cliente muda de cidade ou estado, o registro anterior recebe scd_end_date e scd_is_current = FALSE, e um novo registro e inserido. Isso preserva o historico completo de localizacao, permitindo analises corretas para qualquer ponto no tempo.

customer_key	customer_unique_id	city	state	scd_start	scd_end	is_current
1	abc123...	Sao Paulo	SP	2017-01-15	2018-03-10	FALSE
2	abc123...	Campinas	SP	2018-03-11	NULL	TRUE

2.3 Metricas da Tabela Fato

Metrica	Tipo	Descricao
price	DECIMAL	Preco do produto
freight_value	DECIMAL	Valor do frete
total_revenue	DECIMAL	Receita total (price + freight)
payment_value	DECIMAL	Valor total pago pelo cliente
review_score	INTEGER	Avaliacao 1-5 (NULL se nao avaliou)
days_to_delivery	INTEGER	Dias da compra ate entrega real
delivery_delay	INTEGER	Atraso em dias (negativo = adiantado)

3. Pipeline ETL/ELT

O pipeline e organizado em 6 scripts SQL mais um script Python de setup. Todos sao idempotentes: podem ser reexecutados sem duplicar dados (DELETE + INSERT ou DROP + CREATE).

Script	Camada	O que faz
setup_dw.py	Orquestrador	Executa todo o pipeline de uma vez, detecta caminhos automaticamente
00_staging.sql	Staging	Views sobre os 9 CSVs brutos via read_csv_auto()
01_oltp.sql	OLTP	Normaliza, remove duplicatas, trata NULLs, traduz categorias
02_dw_model.sql	DW Model	DDL das 4 dimensoes e fact_sales (estrutura vazia)
03_etl_load.sql	ETL Load	Popula dim_date (1461 dias), SCD2, dimensoes e fato
04_analytics.sql	Analytics	5 consultas analiticas de negocio
05_performance.sql	Performance	Tabela agregada agg_monthly_sales + EXPLAIN ANALYZE

3.1 Qualidade de Dados

- Clientes deduplicados por customer_unique_id (mesmo cliente, varios pedidos = 1 linha no DW)
- Avaliacoes deduplicadas por pedido (retida a mais recente)
- Pagamentos consolidados por pedido (multiplos metodos somados)
- NULLs numericos substituidos por 0 via COALESCE
- Timestamps convertidos com TRY_CAST (erros nao quebram o pipeline)

- Categorias traduzidas do portugues para ingles
- Pedidos cancelados/indisponiveis excluidos das analises de receita


3.2 Resultado da Carga

Tabela	Tipo	Linhas
dim_date	Dimensao	1.461
dim_customer	Dimensao (SCD2)	96.096
dim_product	Dimensao	32.951
dim_seller	Dimensao	3.095
fact_sales	Fato	112.650
agg_monthly_sales	Agregada	~1.200

4. Consultas Analiticas e Insights

4.1 Evolucao de Vendas Mensais (Query 1 - Analise Temporal)


A analise temporal mostra que as vendas do Olist cresceram de forma expressiva ao longo do periodo. A receita mensal saiu de cerca de R\$ 51 mil em outubro de 2016 para um pico de R\$ 1,1 milhao em novembro de 2017 (Black Friday), recuando levemente em seguida e estabilizando em torno de R\$ 800 mil a R\$ 1 milhao no segundo semestre de 2018. O numero de pedidos seguiu trajetoria semelhante, confirmando crescimento organico da plataforma e nao apenas aumento de ticket medio.



4.2 Top 10 Categorias por Receita (Query 2 - Ranking)


As categorias Health & Beauty, Watches & Gifts e Bed/Bath/Table lideram o ranking de receita, juntas representando quase 30% do faturamento total. Destaca-se que categorias de alto valor unitario como Computers & Accessories e Furniture & Decor aparecem no top

10 mesmo com menor volume de pedidos, indicando alto ticket medio. Essa informacao orienta decisoes de sortimento, comissao e campanhas de marketing.







4.3 Receita por Categoria x Estado (Query 3 - Multidimensional)

O mapa de calor evidencia a dominancia do estado de SP em praticamente todas as categorias, especialmente em Health & Beauty, Watches e Bed/Bath, onde a receita paulista e 5 a 10 vezes maior que a do segundo colocado (RJ). Estados como MG, RS e PR formam um segundo bloco consistente. Regioes Norte e Nordeste aparecem fracamente mesmo nas categorias lideres, indicando oportunidade de expansao logistica para capturar demanda reprimida.



4.4 Cohort, KPI por Estado (Queries 4 e 5)

A análise de cohort mostra aceleração de aquisição de clientes a partir de março de 2017, com pico em novembro de 2017. A taxa de retenção mantém-se baixa (~3-5%), confirmando que o Olist opera predominantemente com compras únicas, padrão esperado para e-commerce de itens duráveis. No KPI por estado, PB, SE e RN apresentam os maiores tickets médios, enquanto SP e RJ tem maior volume absoluto. O prazo médio de entrega varia de 8 dias (SP) a mais de 25 dias (estados do Norte), refletindo o desafio logístico brasileiro.



5. Performance e Otimização

Foi criada a tabela agregada `agg_monthly_sales` pre-computando receita, pedidos, avaliação e ticket médio por (ano, mes, categoria, estado). O ganho de performance é expressivo:

Estratégia	Linhas processadas	Tempo estimado
Query direta na <code>fact_sales</code>	112.650	~1,2s
Query na <code>agg_monthly_sales</code>	~1.200	~0,04s
Ganho	94x menos linhas	~30x mais rápido

6. Bonus Implementados

Todos os 4 bonus previstos na rubrica foram implementados, totalizando ate +20% na nota.

6.1 Dashboard Interativo — Streamlit Cloud (+5%)

Dashboard publicado e acessivel publicamente via Streamlit Cloud, sem necessidade de instalacao. Funcionalidades implementadas:

- Filtros por ano, categoria e estado na sidebar
- Grafico de linha interativo com alternancia entre receita, pedidos e avaliacao
- Ranking de categorias com slider (5 a 15) e 3 opcoes de ordenacao
- Grafico de pizza de formas de pagamento com percentuais
- Distribuicao de avaliacoes (histograma por estrelas)
- KPIs por estado com 4 ordenacoes e tabela expansivel

Acesso: <https://projeto-dw-olist.streamlit.app>

6.2 Testes Automatizados (+5%)

Script tests/test_dw.py com 13 testes de integridade organizados em 7 categorias:

Categoria	Testes	O que valida
Contagem de linhas	6	Minimo de linhas em cada tabela do DW
Chaves primarias	4	Ausencia de duplicatas nas PKs
Integridade referencial	4	Todas as FKs existem nas dimensoes
Campos obrigatorios	4	Ausencia de NULLs em colunas criticas
Valores invalidos	3	Precos negativos, notas fora de 1–5
SCD Type 2	2	Maximo 1 registro current por cliente
Metricas de negocio	4	Receita, ticket medio e avaliacao dentro do esperado

Resultado: 13/13 testes passaram — todos os checks de integridade aprovados.

6.3 PostgreSQL + DuckDB — Comparacao (+5%)

Script bonus/postgres_etl.py que carrega o mesmo DW no PostgreSQL 18 e compara performance de uma query OLAP tipica nos dois bancos:

Engine	Caracteristica	Tempo tipico
DuckDB 1.5.3 (colunar, OLAP)	Nativo para analytics	~15 ms
PostgreSQL 18 (row store, OLTP)	Nativo para transacoes	~150–300 ms
Conclusao	DuckDB mais rapido	~10–20x para OLAP

O PostgreSQL e ideal para insercoes e atualizacoes frequentes (OLTP). O DuckDB e ideal para leitura analitica em larga escala (OLAP/BI). Para um DW em producao, a arquitetura

recomendada e: PostgreSQL para ingestão de dados transacionais + DuckDB (ou BigQuery) para a camada analítica.

7. Conclusão

O projeto entrega um Data Warehouse completo e funcional, desde a ingestão dos CSVs brutos até o dashboard publicado em produção. Os principais resultados:

- **Crescimento de 20x:** a plataforma Olist cresceu de R\$ 51 mil/mes em out/2016 para R\$ 1 milhão/mes em nov/2017, com pico na Black Friday.
- **Concentração geográfica:** SP representa mais de 38% da receita total, mas estados nordestinos têm ticket médio acima da média nacional.
- **Desigualdade logística:** prazo médio varia de 8,7 dias (SP) a 28,2 dias (AP e RR), revelando oportunidade de melhoria na logística para regiões remotas.
- **Baixa retenção:** ~95% dos clientes compraram apenas uma vez, padrão esperado para e-commerce de itens duráveis.
- **Integridade garantida:** 13/13 testes automatizados passando, confirmando a qualidade do pipeline ETL.
- **DuckDB superior para OLAP:** 10 a 20x mais rápido que PostgreSQL para queries analíticas típicas de DW.

O DW construído serve como base para expansão futura: integração com Power BI ou Looker Studio, previsão de demanda por machine learning, implementação de alertas automáticos para quedas de NPS ou aumento de atrasos de entrega.

Referencias

OLIST. Brazilian E-Commerce Public Dataset by Olist. Kaggle, 2018. Disponível em: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

KIMBALL, R.; ROSS, M. The Data Warehouse Toolkit. 3. ed. Wiley, 2013.

DUCKDB. DuckDB Documentation. Versao 1.5. Disponível em: <https://duckdb.org/docs/>

PLOTLY. Plotly Python Open Source Graphing Library. Disponível em: <https://plotly.com/python/>

STREAMLIT. Streamlit Documentation. Disponível em: <https://docs.streamlit.io/>

POSTGRESQL. PostgreSQL 18 Documentation. Disponível em: <https://www.postgresql.org/docs/18/>