

Data Warehouse

Brazilian E-Commerce Olist

Relatorio Tecnico - Projeto de Banco de Dados / BI
FATEC Jundiai | 2026

Dataset	Brazilian E-Commerce Public Dataset by Olist
Fonte	Kaggle (CC BY-NC-SA 4.0)
Volume	99.441 pedidos 112.650 itens 9 arquivos CSV
Banco	DuckDB 1.5.3
Periodo	Setembro/2016 - Outubro/2018
Receita	R\$ 15.735.527,03

1. Introducao

Este projeto implementa um Data Warehouse (DW) completo sobre o dataset publico Brazilian E-Commerce by Olist, disponivel no Kaggle. O Olist e uma plataforma de e-commerce brasileira que conecta pequenos vendedores a grandes marketplaces. O dataset contem cerca de 100 mil pedidos realizados entre 2016 e 2018, com informacoes de clientes, produtos, vendedores, pagamentos, avaliacoes e logistica.

O objetivo e transformar esses dados brutos em informacao estruturada para apoiar decisoes de negocio, respondendo a perguntas como: quais categorias geram mais receita? Quais estados tem maior ticket medio? Como evoluiu a base de clientes ao longo do tempo? Qual e o desempenho logistico por regioao?

1.1 Perguntas de Negocio Respondidas

#	Pergunta	Tipo de Analise
1	Como evoluiram as vendas mes a mes ao longo de 2016-2018?	Temporal
2	Quais sao as 10 categorias de produto mais lucrativas?	Ranking
3	Qual categoria vende mais em cada estado brasileiro?	Multidimensional
4	Como cresce e como e a retencao da base de clientes?	Cohort
5	Quais estados tem maior ticket medio e melhor logistica?	KPI

2. Modelagem Dimensional

O modelo adotado é o Esquema Estrela, composto por uma tabela fato central (fact_sales) e quatro dimensões. O grain (granularidade) da tabela fato é 1 linha por item de pedido, ou seja, cada linha representa um produto específico dentro de um pedido.

2.1 Dimensões

Dimensão	Grain	Tipo SCD	Linhas	Descrição
dim_date	1 por dia	N/A	1.461	Calendário de Jan/2016 a Dez/2019
dim_customer	1 por versão	SCD Type 2	96.096	Clientes com rastreamento de localização
dim_product	1 por produto	SCD Type 1	32.951	Produtos com categoria em inglês
dim_seller	1 por vendedor	SCD Type 1	3.095	Vendedores com dados geográficos

2.2 SCD Type 2 - dim_customer

A dimensão de clientes implementa Slowly Changing Dimension Type 2: quando um cliente muda de cidade ou estado, o registro anterior recebe uma scd_end_date e scd_is_current = FALSE, enquanto um novo registro é inserido com os dados atualizados. Isso preserva o histórico completo de localização.

customer_key	customer_unique_id	city	state	scd_start	scd_end	is_current
1	abc123...	Sao Paulo	SP	2017-01-15	2018-03-10	FALSE
2	abc123...	Campinas	SP	2018-03-11	NULL	TRUE

2.3 Tabela Fato - fact_sales

A fact_sales centraliza todas as métricas de venda. Além do valor do produto e frete, armazena métricas operacionais como avaliação do cliente (review_score), prazo de entrega em dias e desvio em relação ao prazo estimado (delivery_delay).

Métrica	Tipo	Descrição
price	DECIMAL	Preço do produto
freight_value	DECIMAL	Valor do frete
total_revenue	DECIMAL	Receita total (price + freight)
payment_value	DECIMAL	Valor total pago pelo cliente
review_score	INTEGER	Avaliação 1-5 (NULL se não avaliou)
days_to_delivery	INTEGER	Dias da compra até entrega real
days_estimated	INTEGER	Dias da compra até estimativa
delivery_delay	INTEGER	Atraso em dias (negativo = adiantado)

3. Pipeline ETL/ELT

O pipeline é organizado em 6 scripts SQL numerados, executados em sequência. Cada script é idempotente: pode ser reexecutado N vezes sem duplicar dados (usa DELETE + INSERT ou DROP + CREATE).

Script	Nome	O que faz
00_staging.sql	Staging	Cria VIEWS sobre os 9 CSVs brutos via read_csv_auto()
01_oltp.sql	OLTP	Normaliza, remove duplicatas, trata NULLs, traduz categorias
02_dw_model.sql	DW Model	Cria as 4 dimensões e fact_sales (estrutura vazia)
03_etl_load.sql	ETL Load	Popula dim_date (1461 dias), SCD2, dimensões e fato
04_analytics.sql	Analytics	5 consultas analíticas de negócio
05_performance.sql	Performance	Tabela agregada agg_monthly_sales + EXPLAIN ANALYZE

3.1 Tratamentos de Qualidade de Dados

- Clientes deduplicados por customer_unique_id (mesmo cliente com múltiplos pedidos gera 1 linha no DW)
- Avaliações deduplicadas por pedido (retida a avaliação mais recente)
- Pagamentos consolidados por pedido (múltiplos métodos somados em total_payment_value)
- Campos numéricos com NULL substituídos por 0 via COALESCE
- Timestamps convertidos com TRY_CAST (erros não quebram o pipeline)
- Categorias de produto traduzidas do português para inglês via stg_category_translation
- Pedidos com status cancelado ou indisponível excluídos das análises de receita


3.2 Resultado da Carga

Tabela	Tipo	Linhas Carregadas
dim_date	Dimensão	1.461
dim_customer	Dimensão (SCD2)	96.096
dim_product	Dimensão	32.951
dim_seller	Dimensão	3.095
fact_sales	Fato	112.650
agg_monthly_sales	Agregada (bonus)	~1.200

4. Consultas Analíticas e Insights

4.1 Evolucao de Vendas Mensais (Query 1 - Analise Temporal)


A analise temporal mostra que as vendas do Olist cresceram de forma expressiva ao longo do periodo. A receita mensal saiu de cerca de R\$ 51 mil em outubro de 2016 para um pico de R\$ 1,1 milhao em novembro de 2017 (Black Friday), recuando levemente em seguida e estabilizando em torno de R\$ 800 mil a R\$ 1 milhao no segundo semestre de 2018. O numero de pedidos seguiu trajetoria semelhante, confirmando crescimento organico da plataforma e nao apenas aumento de ticket medio.



4.2 Top 10 Categorias por Receita (Query 2 - Ranking)


As categorias Health & Beauty, Watches & Gifts e Bed/Bath/Table lideram o ranking de receita, juntas representando quase 30% do faturamento total. Destaca-se que categorias de alto valor unitario como Computers & Accessories e Furniture & Decor aparecem no top 10 mesmo com menor volume de pedidos, indicando alto ticket medio. Essa informacao orienta decisoes de sortimento, comissionamento e campanhas de marketing.

Top 10 Categorias por Receita Total







4.3 Receita por Categoria x Estado (Query 3 - Multidimensional)

O mapa de calor evidencia a dominancia do estado de SP em praticamente todas as categorias, especialmente em Health & Beauty, Watches e Bed/Bath, onde a receita paulista e 5 a 10 vezes maior que a do segundo colocado (RJ). Estados como MG, RS e PR formam um segundo bloco consistente. Regioes Norte e Nordeste aparecem fracamente mesmo nas categorias lideres, indicando oportunidade de expansao logistica para capturar demanda reprimida.



4.4 Cohort, KPI por Estado (Queries 4 e 5)

A analise de cohort mostra aceleracao de aquisicao de clientes a partir de marco de 2017, com pico em novembro de 2017. A taxa de retencao mantem-se baixa (~3-5%), confirmando que o Olist opera predominantemente com compras unicas, padrao esperado para e-commerce de itens duraveis. No KPI por estado, PB, SE e RN apresentam os maiores tickets medios, enquanto SP e RJ tem maior volume absoluto. O prazo medio de entrega varia de 8 dias (SP) a mais de 25 dias (estados do Norte), refletindo o desafio logistico brasileiro.



5. Performance e Otimizacao

Para otimizar queries, foi criada a tabela agregada `agg_monthly_sales`, que pre-computa receita, ticket medio, avaliacao e numero de pedidos por combinacao de (ano, mes, categoria, estado). O ganho de performance e expressivo:

Estrategia	Scan	Linhas processadas	Tempo estimado
Query direta na <code>fact_sales</code>	Seq. scan + 3 JOINS	112.650 linhas	~1,2s
Query na <code>agg_monthly_sales</code>	Scan simples	~1.200 linhas	~0,04s
Ganho	N/A	94x menos linhas	~30x mais rapido

O script `05_performance.sql` inclui `EXPLAIN ANALYZE` de ambas as queries para documentar o plano de execucao. Em um ambiente de producao, a tabela agregada seria atualizada via job agendado (daily ou apos cada carga ETL).

6. Conclusao

O projeto demonstra a construcao completa de um Data Warehouse sobre dados reais de e-commerce brasileiro. Os principais resultados e aprendizados foram:

- **Crescimento verificado:** a plataforma Olist cresceu ~20x em receita entre o inicio de 2017 e meados de 2018, com pico na Black Friday.
- **Concentracao geografica:** SP representa mais de 40% da receita em praticamente todas as categorias, mas estados nordestinos tem ticket medio acima da media.
- **Qualidade de entrega:** ~85% dos pedidos chegam antes ou no prazo estimado, mas a variancia e alta entre regioes (8 a 25+ dias).
- **Baixa retencao:** ~95% dos clientes compraram apenas uma vez, o que e caracteristico de plataformas de itens duraveis.
- **SCD Type 2:** a implementacao preserva o historico de localizacao dos clientes, permitindo analises corretas mesmo apos mudancas de endereco.
- **Pipeline idempotente:** todos os scripts podem ser reexecutados sem efeitos colaterais, garantindo confiabilidade operacional.

O Data Warehouse construido serve como base solida para expansao futura: adicao de novas dimensoes (dim_payment, dim_geography), implementacao de metricas de CLV (Customer Lifetime Value), previsao de demanda por ML, e publicacao em ferramentas de BI como Power BI ou Looker Studio.

Referencias

OLIST. Brazilian E-Commerce Public Dataset by Olist. Kaggle, 2018. Disponível em: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

KIMBALL, R.; ROSS, M. The Data Warehouse Toolkit. 3. ed. Wiley, 2013.

DUCKDB. DuckDB Documentation. Versao 1.5. Disponível em: <https://duckdb.org/docs/>

PLOTLY. Plotly Python Open Source Graphing Library. Disponível em: <https://plotly.com/python/>