

Data Warehouse

Brazilian E-Commerce Olist

Relatório Técnico — Projeto de Banco de Dados / BI
FATEC Jundiaí | 2025

Dataset:	Brazilian E-Commerce Public Dataset by Olist
Fonte:	Kaggle (CC BY-NC-SA 4.0)
Volume:	99.441 pedidos 112.650 itens 9 arquivos CSV
Banco:	DuckDB 1.5.3
Período:	Setembro/2016 – Outubro/2018
Receita Total:	R\$ 15.735.527,03

1. Introdução

Este projeto implementa um Data Warehouse (DW) completo sobre o dataset público **Brazilian E-Commerce by Olist**, disponível no Kaggle. O Olist é uma plataforma de e-commerce brasileira que conecta pequenos vendedores a grandes marketplaces. O dataset contém cerca de 100 mil pedidos realizados entre 2016 e 2018, com informações de clientes, produtos, vendedores, pagamentos, avaliações e logística.

O objetivo é transformar esses dados brutos em informação estruturada para apoiar decisões de negócio, respondendo a perguntas como: quais categorias geram mais receita? Quais estados têm maior ticket médio? Como evoluiu a base de clientes ao longo do tempo? Qual é o desempenho logístico por região?

Perguntas de negócio respondidas:

#	Pergunta	Tipo de Análise
1	Como evoluíram as vendas mês a mês ao longo de 2016–2018?	Temporal
2	Quais são as 10 categorias de produto mais lucrativas?	Ranking
3	Qual categoria vende mais em cada estado brasileiro?	Multidimensional
4	Como cresce e como é a retenção da base de clientes?	Cohort
5	Quais estados têm maior ticket médio e melhor logística?	KPI

2. Modelagem Dimensional

O modelo adotado é o **Esquema Estrela**, composto por uma tabela fato central (*fact_sales*) e quatro dimensões. O grain (granularidade) da tabela fato é **1 linha por item de pedido**, ou seja, cada linha representa um produto específico dentro de um pedido.

2.1 Dimensões

Dimensão	Grain	Tipo SCD	Linhas	Descrição
dim_date	1 por dia	—	1.461	Calendário de Jan/2016 a Dez/2019
dim_customer	1 por versão de cliente	SCD Type 2	96.096	Clientes únicos com rastreamento de localização
dim_product	1 por produto	SCD Type 1	32.951	Produtos com categoria traduzida para inglês
dim_seller	1 por vendedor	SCD Type 1	3.095	Vendedores com dados geográficos

2.2 SCD Type 2 — dim_customer

A dimensão de clientes implementa **Slowly Changing Dimension Type 2**: quando um cliente muda de cidade ou estado, o registro anterior recebe uma *scd_end_date* e *scd_is_current* = *FALSE*, enquanto um novo registro é inserido com os dados atualizados. Isso preserva o histórico completo de localização.

customer_key	customer_unique_id	city	state	scd_start	scd_end	is_current
1	abc123...	São Paulo	SP	2017-01-15	2018-03-10	FALSE
2	abc123...	Campinas	SP	2018-03-11	NULL	TRUE

2.3 Tabela Fato — fact_sales

A *fact_sales* centraliza todas as métricas de venda. Além do valor do produto e frete, armazena métricas operacionais como avaliação do cliente (*review_score*), prazo de entrega em dias e desvio em relação ao prazo estimado (*delivery_delay*).

Métrica	Tipo	Descrição
price	DECIMAL	Preço do produto
freight_value	DECIMAL	Valor do frete
total_revenue	DECIMAL	Receita total (price + freight)
payment_value	DECIMAL	Valor total pago pelo cliente
review_score	INTEGER	Avaliação 1–5 (NULL se não avaliou)
days_to_delivery	INTEGER	Dias da compra até entrega real
days_estimated	INTEGER	Dias da compra até estimativa
delivery_delay	INTEGER	Atraso em dias (negativo = adiantado)

3. Pipeline ETL/ELT

O pipeline é organizado em 5 scripts SQL numerados, executados em sequência. Cada script é **idempotente**: pode ser reexecutado N vezes sem duplicar dados (usa DELETE + INSERT ou DROP + CREATE).

Script	Nome	O que faz
00_staging.sql	Staging	Cria VIEWS sobre os 8 CSVs brutos via read_csv_auto()
01_oltp.sql	OLTP	Normaliza, remove duplicatas, trata NULLs, traduz categorias
02_dw_model.sql	DW Model	Cria as 4 dimensões e fact_sales (estrutura vazia)
03_etl_load.sql	ETL Load	Popula dim_date (1461 dias), SCD2, dimensões e fato
04_analytics.sql	Analytics	5 consultas analíticas de negócio
05_performance.sql	Performance	Tabela agregada agg_monthly_sales + EXPLAIN ANALYZE

3.1 Tratamentos de Qualidade de Dados

- Clientes deduplicados por **customer_unique_id** (mesmo cliente com múltiplos pedidos gera 1 linha no DW);
- Avaliações deduplicadas por pedido (retida a avaliação mais recente);
- Pagamentos consolidados por pedido (múltiplos métodos somados em total_payment_value);
- Campos numéricos com NULL substituídos por 0 via COALESCE;
- Timestamps convertidos com TRY_CAST (erros não quebram o pipeline);
- Categorias de produto traduzidas do português para inglês (stg_category_translation);
- Pedidos com status cancelado ou indisponível excluídos das análises de receita.

3.2 Resultado da Carga

Tabela	Tipo	Linhas Carregadas
dim_date	Dimensão	1.461
dim_customer	Dimensão (SCD2)	96.096
dim_product	Dimensão	32.951
dim_seller	Dimensão	3.095
fact_sales	Fato	112.650
agg_monthly_sales	Agregada (bônus)	~1.200

4. Consultas Analíticas e Insights

4.1 Evolução de Vendas Mensais (Query 1 — Análise Temporal)

A análise temporal mostra que as vendas do Olist cresceram de forma expressiva ao longo do período. A receita mensal saiu de cerca de R\$ 51 mil em outubro de 2016 para um pico de **R\$ 1,1 milhão em novembro de 2017** (Black Friday), recuando levemente em seguida e estabilizando em torno de R\$ 800 mil–R\$ 1 milhão no segundo semestre de 2018. O número de pedidos seguiu trajetória semelhante, confirmando crescimento orgânico da plataforma e não apenas aumento de ticket médio.




Figura 1 — Receita total e número de pedidos por mês (2016–2018)

4.2 Top 10 Categorias por Receita (Query 2 — Ranking)

As categorias **Health & Beauty**, **Watches & Gifts** e **Bed/Bath/Table** lideram o ranking de receita, juntas representando quase 30% do faturamento total. Destaca-se que categorias de alto valor unitário como *Computers & Accessories* e *Furniture & Decor* aparecem no top 10 mesmo com menor volume de pedidos, indicando alto ticket médio. Essa informação orienta decisões de sortimento, comissionamento e campanhas de marketing.




Figura 2 — Top 10 categorias de produto por receita total

4.3 Receita por Categoria × Estado (Query 3 — Multidimensional)

O mapa de calor evidencia a dominância do estado de **SP** em praticamente todas as categorias — especialmente em Health & Beauty, Watches e Bed/Bath, onde a receita paulista é 5 a 10 vezes maior que a do segundo colocado (RJ). Estados como **MG, RS e PR** formam um segundo bloco consistente. Regiões Norte e Nordeste aparecem fracamente mesmo nas categorias líderes, indicando oportunidade de expansão logística para capturar demanda reprimida.




Figura 3 — Mapa de calor: receita (R\$ mil) por categoria × estado

4.4 Cohort, KPI por Estado e Dashboard (Queries 4 e 5)

A análise de cohort mostra aceleração de aquisição de clientes a partir de março de 2017, com pico em novembro de 2017. A taxa de retenção mantém-se baixa (~3–5%), confirmando que o Olist opera predominantemente com compras únicas — padrão esperado para e-commerce de itens duráveis. No KPI por estado, **PB, SE e RN** apresentam os maiores tickets médios, enquanto **SP e RJ** têm maior volume absoluto. O prazo médio de entrega varia de 8 dias (SP) a mais de 25 dias (estados do Norte), refletindo o desafio logístico brasileiro.

Dashboard Executivo — Olist E-Commerce




Figura 4 — Dashboard executivo: cohort, KPI por estado, prazo e retenção

5. Performance e Otimização

Para otimizar queries de dashboard, foi criada a tabela agregada **agg_monthly_sales**, que pré-computa receita, ticket médio, avaliação e número de pedidos por combinação de (ano, mês, categoria, estado). O ganho de performance é expressivo:

Estratégia	Scan	Linhas processadas	Tempo estimado
Query direta na fact_sales	Seq. scan + 3 JOINS	112.650 linhas	~1,2s
Query na agg_monthly_sales	Scan simples	~1.200 linhas	~0,04s
Ganho	—	94x menos linhas	~30x mais rápido

O script *05_performance.sql* inclui EXPLAIN ANALYZE de ambas as queries para documentar o plano de execução. Em um ambiente de produção, a tabela agregada seria atualizada via job agendado (daily ou após cada carga ETL).

6. Conclusão

O projeto demonstra a construção completa de um Data Warehouse sobre dados reais de e-commerce brasileiro. Os principais resultados e aprendizados foram:

- **Crescimento verificado:** a plataforma Olist cresceu ~20x em receita entre o início de 2017 e meados de 2018, com pico na Black Friday.
- **Concentração geográfica:** SP representa mais de 40% da receita em praticamente todas as categorias, mas estados nordestinos têm ticket médio acima da média.
- **Qualidade de entrega:** ~85% dos pedidos chegam antes ou no prazo estimado, mas a variância é alta entre regiões (8 a 25+ dias).
- **Baixa retenção:** ~95% dos clientes compraram apenas uma vez, o que é característico de plataformas de itens duráveis.
- **SCD Type 2:** a implementação preserva o histórico de localização dos clientes, permitindo análises corretas mesmo após mudanças de endereço.
- **Pipeline idempotente:** todos os scripts podem ser reexecutados sem efeitos colaterais, garantindo confiabilidade operacional.

O Data Warehouse construído serve como base sólida para expansão futura: adição de novas dimensões (dim_payment, dim_geography), implementação de métricas de CLV (Customer Lifetime Value), previsão de demanda por ML, e publicação em ferramentas de BI como Power BI ou Looker Studio.

Referências

- OLIST. *Brazilian E-Commerce Public Dataset by Olist*. Kaggle, 2018. Disponível em: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>
- KIMBALL, R.; ROSS, M. *The Data Warehouse Toolkit*. 3. ed. Wiley, 2013.
- DUCKDB. *DuckDB Documentation*. Versão 1.5. Disponível em: <https://duckdb.org/docs/>
- PLOTLY. *Plotly Python Open Source Graphing Library*. Disponível em: <https://plotly.com/python/>